Laporan Akhir Kelompok E
Analisis Data Transaksi Coffee Shop: Clustering K-Means, Evaluasi Silhouette Score, dan Interpretasi AI



Mentor:
Cynthia Dhevy Retno Palupi

Disusun Oleh:

1.	Ranya Salma Aqila	22030214097	Universitas Negeri Surabaya
2.	Raihan Fawwaz Naufal	22155202133	Insitut Bisnis Muhammadiyah Bekasi
3.	Naila Hariri	220631100043	Universitas Trunojoyo Madura
4.	Rubben Siahaan	2210501076	Universitas Pembangunan Nasional Veteran Jakarta

PT. MITRA TALENTA GRUP
CELERATES
2024

Kata Pengantar

Puji syukur kami panjatkan ke hadirat Tuhan Yang Maha Esa atas limpahan rahmat dan karunia-Nya, sehingga kami dapat menyelesaikan proyek akhir ini dengan baik. Proyek ini merupakan bagian dari tugas akhir dalam program Studi Independen yang kami jalani bersama PT. Mitra Talenta Grup.

Laporan ini berjudul "Analisis Data Transaksi Coffee Shop: Clustering K-Means, Evaluasi Silhouette Score, dan Interpretasi AI". Melalui proyek ini, kami melakukan analisis data transaksi pelanggan di sebuah Coffee Shop untuk memahami pola pembelian pelanggan serta mengidentifikasi segmen pasar menggunakan algoritma K-Means Clustering, evaluasi menggunakan Silhouette Score, dan interpretasi hasil menggunakan Large Language Model (LLM). Kami berharap hasil proyek ini dapat memberikan wawasan bermanfaat dalam memahami perilaku pelanggan.

Kami mengucapkan terima kasih sebesar-besarnya kepada:

1. PT. Mitra Talenta Grup atas dukungan dan fasilitas yang diberikan selama proyek berlangsung.
2. Mentor dan Trainer yang telah membimbing kami dengan penuh kesabaran.
3. Tim kerja yang selalu berkolaborasi secara baik selama proses pengerjaan proyek.

Kami menyadari bahwa laporan ini masih memiliki kekurangan, oleh karena itu kami sangat terbuka terhadap kritik dan saran yang membangun untuk perbaikan di masa mendatang. Semoga laporan ini dapat bermanfaat bagi pembaca yang memiliki minat pada bidang analisis data, machine learning, dan pengembangan teknologi berbasis kecerdasan buatan.

Kamis, 19 Januari 2024

Kelompok E

Daftar Isi

Kata Pengantar ii
Daftar Isi iii
Abstrak 4
Bab 1 Pendahuluan 5
1.1 Latar Belakang 5
1.2 Tujuan Proyek 5
1.3 Manfaat Proyek 5
1.4 Lingkup Project 6
Bab 2 Metodologi Project 7
2.1 Deskripsi Dataset 7
2.2 Tahapan Project 7
2.3 Tools dan Teknologi 9
Bab 3 Implementasi dan Hasil 12
3.1 Exploratory Data Analysis (EDA) 12
3.2 Preprocessing Data 12
3.3 Modelling 13
3.4 Evaluasi Model 13
3.5 Interpretasi Hasil 14
3.6 Interpretasi Hasil dengan LLM (Large Language Model) 15
3.7 Visualisasi 18
Bab 4 Penutup 20
4.1 Kesimpulan 20
4.2 Saran 20
Daftar Pustaka 21
Lampiran 22

Abstrak

Proyek ini bertujuan untuk menganalisis pola transaksi pelanggan di sebuah Coffee Shop menggunakan algoritma clustering K-Means. Dengan mengolah dataset yang berisi 750 data transaksi, proyek ini berhasil mengidentifikasi segmen pelanggan berdasarkan atribut seperti harga satuan, total kuantitas, dan total penjualan. Proses clustering dievaluasi menggunakan Silhouette Score untuk memastikan kualitas segmentasi, sementara visualisasi hasil memberikan wawasan yang mendalam tentang distribusi pelanggan di setiap cluster.

Manfaat teknis dari proyek ini mencakup penguasaan teknik analisis data, evaluasi model clustering, dan penerapan Large Language Model (Google Gemini AI) untuk interpretasi hasil. Dari sisi bisnis, proyek ini memberikan dasar untuk strategi pemasaran yang lebih terarah, peningkatan retensi pelanggan, dan optimasi pendapatan. Rekomendasi untuk pengembangan lebih lanjut meliputi eksplorasi algoritma lain, analisis prediktif, dan penerapan hasil pada skala yang lebih luas.

Bab 1
Pendahuluan

1.1 Latar Belakang

Pada era persaingan bisnis yang semakin ketat, analisis data menjadi salah satu kunci keberhasilan dalam pengambilan keputusan strategis. Dalam konteks ini, analisis clustering menawarkan solusi untuk mengelompokkan pelanggan berdasarkan pola transaksi mereka. Proyek ini berfokus pada penerapan metode clustering untuk memahami perilaku pelanggan dari sebuah Coffee Shop. Dengan menggunakan algoritma K-Means, dataset transaksi pelanggan diolah untuk mengidentifikasi kelompok pelanggan berdasarkan atribut seperti harga satuan, total kuantitas, dan total penjualan.

Dataset yang digunakan mencakup 750 baris data dengan atribut seperti tanggal transaksi, nama produk, harga satuan, jumlah kuantitas, kota, dan diskon. Data ini diolah lebih lanjut untuk mendapatkan atribut baru seperti total penjualan, bulan, dan hari dalam minggu. Relevansi dataset ini adalah memberikan wawasan tentang segmen pelanggan sehingga strategi pemasaran dapat lebih ditargetkan dan efektif.

1.2 Tujuan Proyek

Proyek ini bertujuan:

1. Mengelompokkan pelanggan berdasarkan pola transaksi mereka menggunakan algoritma clustering K-Means.
2. Mengidentifikasi karakteristik utama dari setiap kelompok pelanggan untuk mendukung pengambilan keputusan bisnis.
3. Memanfaatkan model kecerdasan buatan seperti Large Language Model (Google Gemini AI) untuk memberikan interpretasi otomatis terhadap hasil clustering.

1.3 Manfaat Proyek

Manfaat dari Proyek ini adalah:

1. Teknis
    - Meningkatkan keterampilan dalam pengolahan data, penerapan metode clustering, dan visualisasi hasil.
    - Mengembangkan pemahaman tentang evaluasi model clustering menggunakan Silhouette Score.
2. Bisnis
    - Memberikan wawasan yang lebih mendalam tentang pola perilaku pelanggan sehingga memungkinkan bisnis untuk membuat strategi pemasaran yang lebih efektif.
    - Memaksimalkan potensi pendapatan dengan fokus pada kelompok pelanggan yang menguntungkan.
    - Mengidentifikasi segmen pelanggan untuk pengembangan produk dan layanan baru.

1.4 Lingkup Project

Lingkup Proyek ini meliputi:

1. Pengumpulan data transaksi pelanggan dari Coffee Shop.
2. Pembersihan dan pemrosesan data termasuk normalisasi fitur numerik.
3. Penerapan algoritma clustering K-Means untuk mengelompokkan data pelanggan.
4. Evaluasi hasil clustering menggunakan Silhouette Score.
5. Visualisasi hasil clustering dengan berbagai alat seperti matplotlib, seaborn, dan Plotly.
6. Interpretasi hasil clustering menggunakan Large Language Model (Google Gemini AI) melalui integrasi dengan LangChain.
7. Pembuatan laporan akhir yang mencakup analisis hasil dan kesimpulan.

Proyek ini dibatasi pada penggunaan Google Collaboratory untuk pengolahan data dan implementasi model machine learning, serta integrasi AI untuk interpretasi hasil.

Bab 2
Metodologi Project

2.1 Deskripsi Dataset

Dataset yang digunakan adalah dataset transaksi dari sebuah kedai kopi yang isi nya merupakan informasi mengenai penjualan produk. Struktur datasetnya sebagai berikut:

1. transaction_date : Menunjukkan tanggal terjadinya transaksi dan merupakan tipe data string.
2. product_name : Nama produk yang dibeli dalam transaksi dan merupakan tipe data string.
3. unit_price : Harga satuan produk dalam Rupiah dan merupakan tipe data integer.
4. total_qty **:** Jumlah unit produk yang dibeli dalam satu transaksi dan merupakan tipe data integer.
5. city : Kota tempat transaksi berlangsung dan merupakan tipe data string
6. discount% : Persentase diskon yang diberikan dalam transaksi dan merupakan tipe data integer.

2.2 Tahapan Project

Uraikan setiap tahap pekerjaan secara rinci:

1. EDA (Exploratory Data Analysis).
   EDA (Exploratory Data Analysis) merupakan Langkah awal pada analisis data yang tujuannya untuk memahami karakteristik dataset. Dalam kode ini, EDA dilakukan dengan Langkah-langkah berikut:
   - Memuat Dataset
     Dataset dimuat dari file CSV menggunakan **pd.read_csv()**
   - Menampilkan Data Awal
     Menampilkan lima baris awal berdasarkan DataFrame untuk mendapatkan gambaran awal mengenai struktur dan isi data menggunakan **df.head**
   - Informasi Dataset
     Gunakan **df.info()** untuk mengetahui tipe data dan jumlah nilai non-null berdasarkan setiap kolom.
   - Statistik Deskriptif
     Gunakan **df.describe()** untuk mendapatkan statistik deskriptif berdasarkan data numerik.
   - Mengecek Missing Values
     Menghitung jumlah nilai yang hilang pada setiap kolom menggunakan **df.isnull().sum()**
   - Visualisasi

Beberapa visualisasi dilakukan untuk memahami distribusi data, seperti distribusi transaksi per kota, per produk, dan distribusi diskon, menggunakan **matplotlib** dan **seaborn.**

2. Preprocessing and Cleaning Data.
   Tujuan dari tahap ini adalah mempersiapkan data untuk dianalisis lebih lanjut. Langkah-langkah yang dilakukan adalah:
   - Menghapus Duplikat
     Data duplikat dihapus menggunakan **df.drop_duplicates()**
   - Menghapus Nilai Negatif
     Data dengan nilai negatif di kolom **unit_price** dan **total_qty** akan dihapus untuk menjaga integritas data.
   - Mengisi Nilai Kosong
     Kolom **discount%** yang memiliki nilai kosong diisi dengan rata-rata kolom tersebut.
   - Menghapus Baris Kosong
     Baris yang memiliki nilai kosong di kolom penting lainnya dihapus menggunakan **df.dropna()**.
   - Menambahkan Kolom Baru
     Kolom baru seperti **total_sales**, **average_price_per_unit**, **month**, dan **day_of_week** ditambahkan untuk analisis lebih lanjut.
   - Normalisasi Data
     Gunakan **MinMaxScaler** untuk menormalkan fitur numerik agar berada dalam rentang [0,1].
3. Training Model Machine Learning.
   Pada tahap ini, menerapkan model clustering K-Means untuk mengelompokkan data. Langkah-langkah yang dilakukan adalah:
   - Dimensi Reduksi
     Gunakan PCA (Principal Component Analysis) untuk mereduksi data dimensi menjadi dua komponen utama untuk memudahkan visualisasi dan analisis.
   - Menentukan Jumlah Cluster Optimal
     Metode Elbow digunakan untuk menentukan jumlah cluster optimal dengan perhitungan WCSS (Within-Cluster Sum of Squares) untuk berbagai jumlah cluster.
   - Evaluasi Silhouette Score
     Silhouette Score dihitung untuk seberapa baik data disimpan. Nilai tertinggi menunjukkan jumlah cluster yang optimal.
   - Clustering dengan K-Means
     Model K-Means dilatih dengan jumlah cluster optimal yang ditemukan pada analisis sebelumnya.
4. Evaluasi Performa Model.

Evaluasi dilakukan untuk menilai seberapa baik model clustering yang diterapkan. Langkah-langkah yang dilakukan adalah:

- Visualisasi 3D
  Silhouette Score dihitung untuk menilai seberapa baik pengumpulan data. Nilai yang lebih tinggi menunjukkan clustering yang lebih baik.
- Analisis Rata-rata per Cluster
  Menampilkan jumlah data untuk setiap cluster, memberikan wawasan tentang karakteristik pelanggan dalam setiap kelompok.

5. Interpretasi Hasil dengan LLM.
   Setelah model dilatih dan di evaluasi, hasil clustering diinterpretasikan menggunakan Large Language Models (LLM) untuk memberikan analisis yang lebih mendalam. Langkah-langkah yang dilakukan adalah:
   - Membuat Tabel Ringkasan
     Fungsi **create_summary_table()** digunakan untuk mengelompokkan data berdasarkan cluster dan menghitung rata-rata untuk beberapa kolom.
   - Integrasi dengan LLM
     Menggunakan model Google Gemini AI untuk memberikan interpretasi hasil clustering. Input API key dilakukan secara aman menggunakan **getpass()**.
   - Membuat Prompt untuk LLM
     Prompt disiapkan untuk meminta LLM menjelaskan hasil clustering berdasarkan tabel ringkasan yang telah dibuat.
   - Menjalankan LLM
     Hasil interpretasi dari LLM ditampilkan, memberikan wawasan tambahan tentang karakteristik setiap cluster.
6. Analisis Hasil.
   Tahap terakhir adalah menganalisis hasil clustering dan menyajikan ringkasan yang mudah dipahami. Langkah-langkah yang dilakukan adalah:
   - Membuat Tabel Ringkasan
     Tabel ringkasan dibuat untuk menampilkan karakteristik setiap cluster, termasuk total penjualan, harga satuan rata-rata, dan jumlah pembelian rata-rata. Ditampilkan dengan format rapi menggunakan **tabulate**.
   - Menampilkan Interpretasi LLM
     Interpretasi yang dihasilkan oleh LLM ditampilkan, memberikan pemahaman yang lebih baik tentang karakteristik setiap cluster.

2.3 Tools dan Teknologi

1. Alat yang digunakan

- Google Collab

  Google Collab adalah layanan dari Google untuk menjalankan dan mengelola notebook Jupyter berbasis cloud secara gratis (Isnanto, 2023). Memiliki kelebihan seperti gratis, mudah digunakan, tidak memerlukan konfigurasi hardware yang kuat dan Integrasi yang baik dengan Google Drive.

2. Library Python yang Digunakan dan Alasannya
   - Pandas

     Deskripsi: Pandas merupakan library Python untuk mengolah dan menganalisis data-data yang terstruktur (Pujiantoro, Sumadikarta, & Priambodo, 2023). Pustaka ini menyediakan struktur data yang efisien dan fleksibel, seperti DataFrame (untuk data tabular) dan Series (untuk data satu dimensi), yang memungkinkan untuk melakukan berbagai operasi pada data, termasuk pembersihan, transformasi, dan analisis statistik.

     Alasan: Pandas memungkinkan melakukan berbagai operasi secara efisien seperti menggabungkan, memfilter, dan menggabungkan data. Hal ini sangat berguna untuk analisis data dan persiapan data sebelum analisis lebih lanjut
   - Matplotlib

     Deskripsi: matplotlib adalah library python paling populer untuk melakukan visualisasi data yang lebih menarik dan mudah dipahami sehingga matplotlib akan terasa lebih alami untuk dipelajari (Tigenes, 2021)
   - Alasan: Visualisasi data adalah langkah penting dalam analisis data untuk memahami pola dan tren. Matplotlib menyediakan fleksibilitas dalam membuat berbagai jenis grafik, seperti garis, batang, dan histogram.
   - Seaborn

     Deskripsi : Seaborn adalah pustaka untuk membuat grafik statistik dalam Python. Pustaka ini dibangun di atas matplotlib dan terintegrasi erat dengan struktur data pandas (Wakom, 2024)

     Alasan: Seaborn memudahkan pembuatan visualisasi yang lebih kompleks dan estetis, yang membantu dalam eksplorasi data dan memberikan wawasan yang lebih dalam.
   - Scikit-learn

     Deskripsi: Scikit-Learn adalah salah satu library yang disediakan oleh Python untuk memproses algoritma Machine Learning (Nursyafitri, 2023)

     Alasan: Dalam kode ini, Scikit-learn digunakan untuk beberapa tujuan:

a. MinMaxScaler: Untuk normalisasi data agar berada dalam rentang [0, 1], yang penting untuk algoritma machine learning .
b. KMeans: Algoritma clustering K-Means digunakan untuk mengelompokkan data berdasarkan kesamaan.
c. Silhouette_Score: Untuk mengevaluasi kualitas clustering dengan menghitung Silhouette Score, yang memberikan gambaran tentang seberapa baik data dikelompokkan.
d. PCA (Principal Component Analysis): Untuk reduksi dimensi, membantu dalam visualisasi dan mempercepat proses clustering.

- Tabulate

  Deskripsi: Tabulate adalah pustaka yang digunakan untuk menampilkan data dalam format tabel yang rapi dan mudah dibaca.

  Alasan: Menampilkan hasil analisis dalam bentuk tabel yang terformat dengan baik membantu dalam pemahaman dan presentasi data, terutama saat menyajikan ringkasan hasil clustering.
- Getpass

  Deskripsi : Getpass digunakan untuk meminta pengguna menggunakan string prompt dan membaca input dari pengguna sebagai Kata Sandi.

  Alasan: Menggunakan Getpass untuk input API key secara aman membantu menjaga kerahasiaan informasi sensitif, yang penting dalam konteks integrasi dengan layanan eksternal
- mpl_toolkits.mplot3d

  Deskripsi : Modul ini adalah bagian dari Matplotlib yang digunakan untuk membuat visualisasi 3D.

  Alasan : Visualisasi 3D membantu dalam memahami data yang memiliki lebih dari dua dimensi, memberikan perspektif yang lebih baik tentang distribusi data dalam ruang tiga dimensi, yang sangat berguna dalam analisis clustering.
- LangChain

  Deskripsi : LangChain adalah salah satu teknologi terbaru yang semakin populer dalam dunia pengembangan aplikasi. Teknologi ini menawarkan cara baru untuk mengelola dan mengintegrasikan berbagai komponen dalam satu platform yang efisien (Dewi, 2024)

  Alasan : LangChain untuk memanfaatkan kemampuan model bahasa generatif. Dengan menggunakan LangChain, dapat dengan mudah mengintegrasikan model AI ke dalam alur kerja, meningkatkan efisiensi dan efektivitas dalam pengolahan data.

Bab 3
Implementasi dan Hasil

3.1 Exploratory Data Analysis (EDA)

Tahap awal dalam penelitian ini dimulai dengan proses Exploratory Data Analysis (EDA) untuk memahami struktur data secara keseluruhan. Dataset yang digunakan di-load ke dalam lingkungan Python menggunakan pustaka Pandas. Proses ini melibatkan pemeriksaan struktur data, seperti jumlah baris, kolom, tipe data, serta jumlah nilai kosong dan duplikat.

Dengan menggunakan fungsi df.info() dan df.describe(), diperoleh informasi mengenai statistik deskriptif dari setiap fitur numerik, seperti nilai rata-rata, minimum, maksimum, dan standar deviasi. Selain itu:

- Deteksi missing values dilakukan dengan isnull() dan dihapus menggunakan dropna() untuk menjaga kualitas data.
- Penghapusan duplikat dilakukan dengan fungsi drop_duplicates() agar tidak terjadi bias dalam analisis.

	unit_price	total_qty	discount%
count	750.000000	750.000000	750.000000
mean	31938.666667	3.090667	10.073333
std	10253.084375	1.427292	7.020946
min	15000.000000	1.000000	0.000000
25%	25000.000000	2.000000	5.000000
50%	30000.000000	3.000000	10.000000
75%	40000.000000	4.000000	15.000000
max	50000.000000	5.000000	20.000000

```
Missing values per column:
 transaction_date    0
product_name         0
unit_price           0
total_qty            0
city                 0
discount%            0
dtype: int64
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 750 entries, 0 to 749
Data columns (total 6 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   transaction_date  750 non-null   object
 1   product_name      750 non-null   object
 2   unit_price        750 non-null   int64
 3   total_qty         750 non-null   int64
 4   city              750 non-null   object
 5   discount%         750 non-null   int64
dtypes: int64(3), object(3)
memory usage: 35.3+ KB
```

Selanjutnya, dilakukan visualisasi distribusi data untuk setiap fitur numerik menggunakan histogram. Visualisasi ini memberikan gambaran mengenai sebaran nilai pada masing-masing kolom, seperti keberadaan outlier atau distribusi yang tidak merata. Selain itu, digunakan pairplot dari pustaka Seaborn untuk melihat hubungan antar variabel numerik, sehingga pola awal dari dataset dapat terlihat dengan jelas. Hasil analisis eksploratif ini memberikan dasar yang kuat untuk mempersiapkan data sebelum masuk ke tahap preprocessing dan pemodelan.

3.2 Preprocessing Data

Setelah tahap eksplorasi data selesai, proses selanjutnya adalah preprocessing data, yaitu menyiapkan data agar siap untuk digunakan dalam proses pemodelan. Tahap ini melibatkan proses:

- Normalisasi data menggunakan metode MinMaxScaler dari pustaka sklearn. Normalisasi dilakukan untuk memastikan semua fitur memiliki skala yang seragam dan menghindari dominasi fitur tertentu dalam algoritma K-Means Clustering.

- Menggunakan MinMaxScaler untuk mengubah data ke rentang [0, 1]

```
[ ] # Menggunakan MinMaxScaler untuk normalisasi data
    scaler = MinMaxScaler()
    numeric_features = ['unit_price', 'total_qty', 'total_sales', 'discount%', 'average_price_per_unit']  # Menambahkan average_price_per_unit
    df[numeric_features] = scaler.fit_transform(df[numeric_features])
```

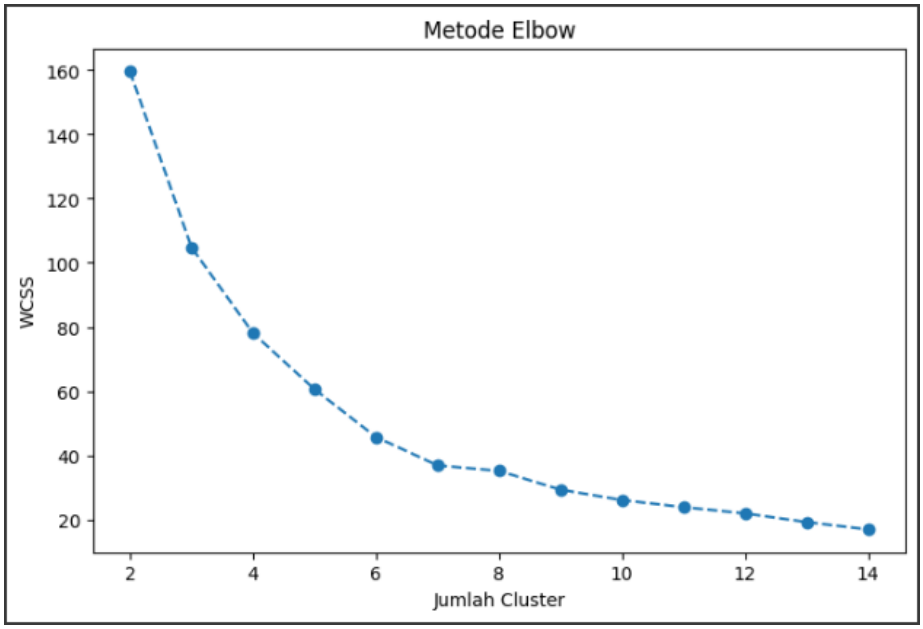
- Transformasi data dilakukan menggunakan fungsi scaler.fit_transform() yang mengubah semua fitur menjadi skala yang terstandardisasi (mean = 0, standard deviation = 1).

Langkah ini sangat penting karena K-Means sangat sensitif terhadap perbedaan skala data. Data yang telah dinormalisasi selanjutnya digunakan sebagai input pada tahap pemodelan.

3.3 Modelling

Tahap pemodelan bertujuan untuk membentuk kelompok atau cluster menggunakan algoritma K-Means Clustering. Proses ini diawali dengan menentukan jumlah cluster optimal menggunakan metode Elbow Method. Langkah-langkahnya meliputi:

- Menghitung WCSS (Within-Cluster Sum of Squares) untuk jumlah cluster yang bervariasi dari 2 hingga 14. WCSS mengukur total jarak kuadrat dari setiap titik data ke pusat cluster terdekat.
- Visualisasi Elbow Curve menggunakan pustaka Matplotlib, di mana titik siku atau "elbow" pada grafik menunjukkan jumlah cluster optimal.



Setelah jumlah cluster optimal diperoleh, model K-Means dilatih menggunakan parameter tersebut. Fungsi fit_predict() digunakan untuk melatih model dan memberikan label cluster pada setiap baris data. Label cluster kemudian ditambahkan sebagai kolom baru dalam dataset, yang menjadi dasar untuk analisis selanjutnya.

3.4 Evaluasi Model

Evaluasi model dilakukan untuk mengukur seberapa baik hasil clustering yang diperoleh. Dalam penelitian ini, digunakan metrik Silhouette Score untuk mengevaluasi kualitas cluster. Langkah ini dilakukan dengan menggunakan fungsi silhouette_score() dari pustaka sklearn.

- Silhouette Score mengukur konsistensi dan kepadatan setiap cluster, dengan nilai berkisar antara -1 hingga 1.
- Nilai optimal: Jika nilai mendekati 1, berarti cluster memiliki kualitas yang baik dan data dalam cluster memiliki jarak yang jelas dengan cluster lainnya.

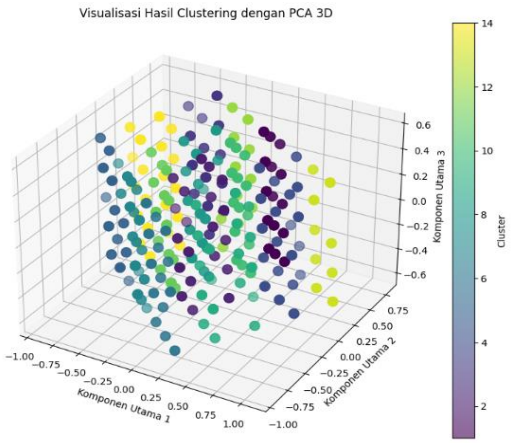
```
Jumlah Cluster: 2, Silhouette Score: 0.37
Jumlah Cluster: 3, Silhouette Score: 0.39
Jumlah Cluster: 4, Silhouette Score: 0.38
Jumlah Cluster: 5, Silhouette Score: 0.39
Jumlah Cluster: 6, Silhouette Score: 0.41
Jumlah Cluster: 7, Silhouette Score: 0.42
Jumlah Cluster: 8, Silhouette Score: 0.39
Jumlah Cluster: 9, Silhouette Score: 0.42
Jumlah Cluster: 10, Silhouette Score: 0.43
Jumlah Cluster: 11, Silhouette Score: 0.43
Jumlah Cluster: 12, Silhouette Score: 0.44
Jumlah Cluster: 13, Silhouette Score: 0.44
Jumlah Cluster: 14, Silhouette Score: 0.46
```

```
Jumlah cluster optimal: 14, Silhouette Score terbaik: 0.46
```

Dengan evaluasi ini, keandalan model K-Means dapat diukur secara objektif, dan hasil clustering dapat dipastikan memiliki kualitas yang optimal.

3.5 Interpretasi Hasil

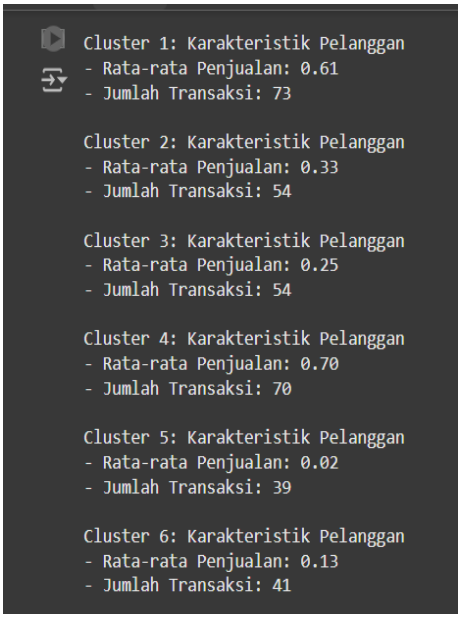
Tahap terakhir adalah interpretasi hasil dari proses clustering. Hasil clustering divisualisasikan dalam bentuk scatter plot 3D menggunakan pustaka Matplotlib. Pada visualisasi ini:



- Setiap titik data diwarnai berdasarkan label clusternya.
- Plot 3D memberikan gambaran distribusi data yang jelas di ruang tiga dimensi.

Selanjutnya, karakteristik dari setiap cluster dianalisis dengan menghitung rata-rata nilai setiap fitur numerik per cluster menggunakan groupby().mean() dari Pandas. Hasil ini memberikan insight sebagai berikut:

- Identifikasi pola unik dalam setiap cluster, seperti fitur mana yang mendominasi di setiap kelompok.
- Perbandingan antar cluster, untuk memahami perbedaan signifikan dalam distribusi fitur.





Dengan interpretasi ini, hasil clustering tidak hanya menghasilkan kelompok data, tetapi juga memberikan wawasan yang mendalam mengenai karakteristik setiap cluster. Hal ini dapat digunakan untuk mendukung pengambilan keputusan berbasis data.

3.6 Interpretasi Hasil dengan LLM (Large Language Model)

Tahap interpretasi hasil clustering dilakukan dengan bantuan teknologi Large Language Model (LLM) yang dapat menganalisis data numerik dan memberikan penjelasan berbasis natural language. Dalam penelitian ini, LLM digunakan untuk memberikan deskripsi mendalam terkait karakteristik masing-masing cluster hasil pemodelan K-Means.

Proses Interpretasi

1. Proses Perancangan LLM

   LLM yang digunakan adalah model Google Generative AI (Gemini 1.5) melalui integrasi API dalam platform Python. Langkah-langkah dalam perancangan LLM melibatkan:

- Input Data: Ringkasan hasil clustering dalam bentuk tabel yang berisi rata-rata setiap fitur numerik untuk tiap cluster. Data ini disiapkan menggunakan groupby().mean() dari Pandas dan diformat menjadi teks dengan pustaka tabulate agar lebih mudah dibaca oleh LLM.
- Prompt Design: Prompt dirancang untuk memberikan instruksi jelas kepada LLM mengenai interpretasi data clustering. Prompt menggunakan template pesan yang mencakup:
  a. Peran AI: "Anda adalah asisten AI yang bertugas menganalisis hasil clustering."
  b. Konteks Data: Tabel ringkasan hasil clustering yang diformat secara rapi.
  c. Pertanyaan: "Apa karakteristik setiap cluster berdasarkan data yang diberikan?"

2. Interaksi dengan LLM

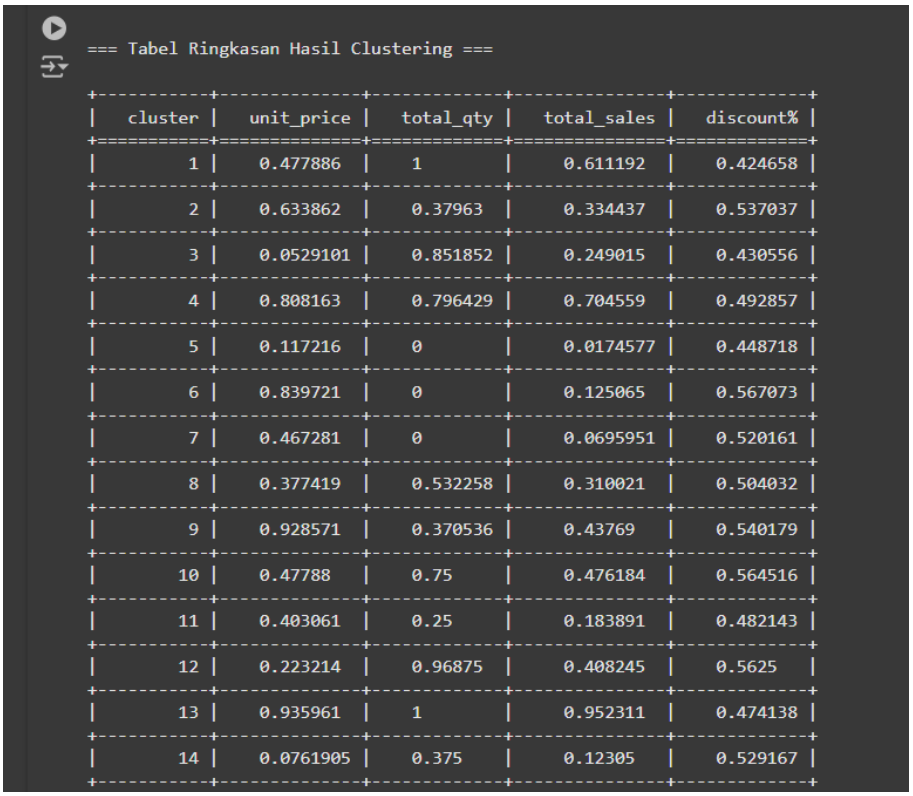
Data clustering yang telah dirangkum selanjutnya diolah dalam bentuk tabular dan disajikan sebagai input bagi LLM. LLM dipanggil melalui API (seperti Google Generative AI) menggunakan prompt yang dirancang khusus untuk menghasilkan interpretasi berbasis teks. Berikut adalah langkah-langkahnya:

- Context Preparation: Data cluster dirangkum dalam format tabel.
- Prompt Engineering: LLM diberi instruksi untuk menganalisis data dan menjawab pertanyaan spesifik mengenai karakteristik setiap cluster.
- Model Response: LLM memberikan penjelasan deskriptif mengenai pola, dominasi fitur, dan potensi penggunaan hasil clustering.

- Capability of LLM (Tools yang Digunakan)
  - Model: Google Generative AI (Gemini 1.5)
  - Platform: Terintegrasi dalam aplikasi menggunakan pustaka langchain_google_genai dan API key.
  - Teknik Prompting: Menggunakan teknik structured prompt dengan peran, instruksi jelas, dan format data tabular untuk memastikan output yang relevan.
  - Analisis Bahasa: LLM mampu membaca tabel input, menganalisis pola data, dan memberikan interpretasi dalam bentuk narasi dengan insight yang mudah dipahami.
  - Kustomisasi Jawaban: LLM dapat menjawab pertanyaan spesifik dari pengguna terkait hasil clustering dan memberikan rekomendasi yang mendukung pengambilan keputusan.

- Output LLM
  - Format Output : Analisis berbasis teks tentang karakteristik setiap cluster.

- Prompt : Analisis tabel hasil clustering ini dan berikan kesimpulan mengenai karakteristik setiap cluster. Apa yang membedakan satu cluster dengan cluster lainnya?
- LLM : Berdasarkan analisis tabel, terlihat adanya segmentasi yang jelas pada data. Cluster 1 dan 4 memiliki harga satuan yang relatif tinggi, serta total penjualan yang cukup besar. Ini mengindikasikan bahwa cluster ini mungkin mewakili produk premium atau produk dengan permintaan tinggi. Sebaliknya, cluster 3 memiliki harga satuan yang sangat rendah dan total penjualan yang relatif kecil, mungkin mewakili produk dengan margin keuntungan yang tipis atau produk promosi. Cluster dengan persentase diskon yang tinggi seperti cluster 6 dan 7 mengindikasikan adanya strategi diskon yang agresif untuk menarik pelanggan.



```
=== Tabel Ringkasan Hasil Clustering ===
```

cluster	unit_price	total_qty	total_sales	discount%
1	0.477886	1	0.611192	0.424658
2	0.633862	0.37963	0.334437	0.537037
3	0.0529101	0.851852	0.249015	0.430556
4	0.808163	0.796429	0.704559	0.492857
5	0.117216	0	0.0174577	0.448718
6	0.839721	0	0.125065	0.567073
7	0.467281	0	0.0695951	0.520161
8	0.377419	0.532258	0.310021	0.504032
9	0.928571	0.370536	0.43769	0.540179
10	0.47788	0.75	0.476184	0.564516
11	0.403061	0.25	0.183891	0.482143
12	0.223214	0.96875	0.408245	0.5625
13	0.935961	1	0.952311	0.474138
14	0.0761905	0.375	0.12305	0.529167

Interpretasi LLM:

Data yang diberikan menunjukkan hasil clustering dari suatu dataset, mungkin terkait dengan penjualan. Setiap cluster direpresentasikan oleh rata-rata ternormalisasi dari beberapa variabel: `unit_price`, `total_qty`, `total_sales`, dan `discount%`. Nilai-nilai ini kemungkinan telah dinormalisasi ke rentang 0-1. Mari kita coba menginterpretasikan setiap cluster berdasarkan karakteristik utama.

Interpretasi Cluster:



Kesimpulan:

Analisis ini menunjukkan segmentasi produk berdasarkan harga, kuantitas terjual, total penjualan, dan tingkat diskon. Beberapa cluster menunjukkan peluang peningkatan penjualan (misalnya, dengan mengurangi diskon pada cluster yang performanya baik), sementara yang lain menunjukkan produk yang perlu ditinjau (misalnya, produk yang tidak terjual di beberapa cluster). Penting untuk diingat bahwa interpretasi ini berdasarkan rata-rata dan normalisasi data. Analisis lebih lanjut mungkin diperlukan untuk memahami detail lebih lanjut dari setiap cluster.

- Manfaat Penggunaan LLM

  Penggunaan LLM dalam tahap ini memberikan beberapa manfaat, antara lain:
  - Otomatisasi Interpretasi Data: Mengurangi pekerjaan manual dalam menganalisis dan merangkum karakteristik cluster.
  - Konsistensi Analisis: Interpretasi yang dihasilkan konsisten dan berdasarkan data yang diberikan.
  - Insight Berbasis Teks: LLM mampu menyusun insight yang lebih manusiawi dan komunikatif dibandingkan sekadar angka atau tabel.
  - Fleksibilitas Pertanyaan: LLM mampu menjawab pertanyaan tambahan yang diajukan pengguna untuk memahami hasil clustering lebih dalam.

3.7 Visualisasi

1. Tabel Data

   Dataset awal, hasil preprocessing, dan ringkasan cluster ditampilkan dalam bentuk tabel menggunakan st.dataframe(). Ini membantu pengguna melihat data mentah maupun hasil pengolahan.
2. Line Chart – Evaluasi Silhouette Score

   Line chart yang dibuat menggunakan Matplotlib dan ditampilkan dengan st.pyplot() membantu pengguna memilih jumlah cluster optimal berdasarkan nilai Silhouette Score tertinggi. Titik "elbow" pada grafik menunjukkan jumlah cluster yang direkomendasikan.
3. Scatter Plot – Visualisasi Cluster

   Scatter plot hasil clustering ditampilkan dengan:
   a. Sumbu X: total_sales.
   b. Sumbu Y: total_qty.
   c. Hue (Warna): Mewakili setiap cluster.

Scatter plot ini membantu pengguna memahami bagaimana data dikelompokkan dalam ruang dua dimensi, serta mengidentifikasi pola antar cluster.

4. Interaktif Slider – Jumlah Cluster
   Melalui komponen slider, pengguna dapat secara interaktif memilih jumlah cluster yang diinginkan, dan hasilnya akan ditampilkan secara real-time.
5. Interaksi AI untuk Interpretasi
   Dengan bantuan Google Generative AI (Gemini), pengguna dapat mengajukan pertanyaan terkait hasil clustering, seperti karakteristik setiap cluster. Hasil interpretasi AI ditampilkan dalam format teks melalui Streamlit.

Bab 4
Penutup

4.1 Kesimpulan

Hasil akhir dari proyek ini menunjukkan bahwa analisis clustering dengan algoritma K- Means berhasil mengelompokkan pelanggan berdasarkan pola transaksi mereka. Proses evaluasi menggunakan Silhouette Score memberikan keyakinan bahwa jumlah cluster yang dipilih cukup optimal dalam menggambarkan karakteristik pelanggan. Visualisasi hasil clustering juga memberikan gambaran yang jelas mengenai distribusi pelanggan di setiap kelompok.

Manfaat teknis yang diperoleh meliputi peningkatan pemahaman dalam pengolahan data, penerapan algoritma clustering, dan evaluasi model. Dari sisi bisnis, proyek ini memberikan wawasan penting tentang segmen pelanggan, yang dapat digunakan untuk menyusun strategi pemasaran yang lebih efektif, meningkatkan retensi pelanggan, dan memaksimalkan pendapatan.

4.2 Saran

Untuk pengembangan lebih lanjut, berikut rekomendasi yang dapat dipertimbangkan:

1. Teknis:
   - Mengintegrasikan lebih banyak fitur dari data transaksi untuk analisis yang lebih mendalam.
   - Mencoba algoritma clustering lain seperti DBSCAN atau Hierarchical Clustering untuk dibandingkan dengan K-Means.
   - Mencoba analisis prediktif untuk memproyeksikan perilaku pelanggan di masa depan.
2. Bisnis:
   - Menggunakan hasil clustering untuk merancang program loyalitas pelanggan yang spesifik untuk setiap segmen.
   - Mengaplikasikan analisis ini ke cabang Coffee Shop lain untuk memahami pola transaksi secara lebih luas.
   - Mengembangkan dashboard interaktif yang memungkinkan pengambilan keputusan berbasis data secara real-time.

Daftar Pustaka

Dewi, E. (2024, September 22). *LangChain : Solusi Efisien Untuk Integrasi Aplikasi*. Retrieved from nevacloud: https://nevacloud.com/blog/langchain-solusi-efisien-untuk-integrasi-aplikasi/

Isnanto, B. A. (2023, Oktober 20). *Google Colab: Definisi, Kelebihan, dan Cara Menggunakan*. Retrieved from detikInet: https://inet.detik.com/cyberlife/d-6992733/google-colab-definisi-kelebihan-dan-cara-menggunakan

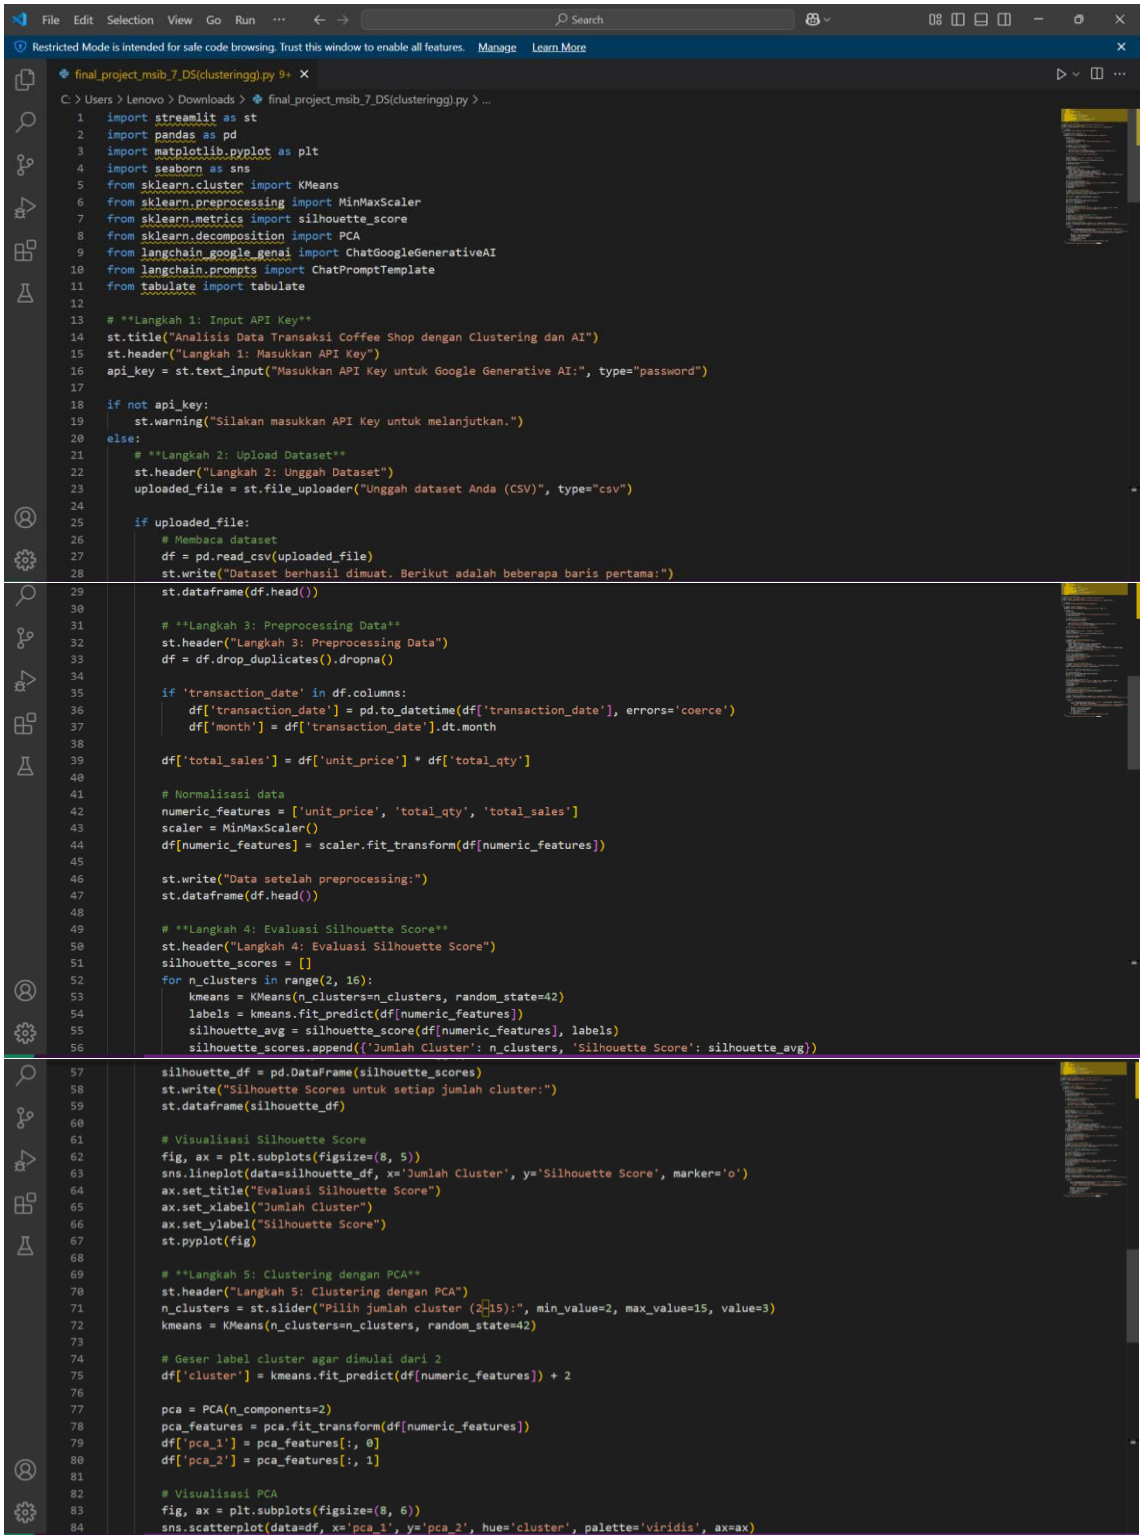
Nursyafitri, G. D. (2023, November 13). *Scikit-Learn, Tools Data Science untuk Machine Learning*. Retrieved from DQLab: https://dqlab.id/scikit-learn-tools-data-science-untuk-machine-learning

Pujiantoro, H., Sumadikarta, I., & Priambodo, A. (2023). PERAMALAN KETAHANAN PANGAN DI DAERAH ISTEMEWA YOGYAKARTA MENGGUNAKAN MODEL SARIMA. 3.

Tigenes, R. (2021, Agustus 30). *Mengenal Matplotlib untuk Visualisasi Data dengan Python*. Retrieved from DQLab: https://dqlab.id/mengenal-matplotlib-untuk-visualisasi-data-dengan-python

Wakom, M. (2024). *Pengenalan Seaborn*. Retrieved from https://seaborn.pydata.org/tutorial/introduction

Lampiran



```python
import streamlit as st
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.cluster import KMeans
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import silhouette_score
from sklearn.decomposition import PCA
from langchain_google_genai import ChatGoogleGenerativeAI
from langchain.prompts import ChatPromptTemplate
from tabulate import tabulate

# **Langkah 1: Input API Key**
st.title("Analisis Data Transaksi Coffee Shop dengan Clustering dan AI")
st.header("Langkah 1: Masukkan API Key")
api_key = st.text_input("Masukkan API Key untuk Google Generative AI:", type="password")

if not api_key:
    st.warning("Silakan masukkan API Key untuk melanjutkan.")
else:
    # **Langkah 2: Upload Dataset**
    st.header("Langkah 2: Unggah Dataset")
    uploaded_file = st.file_uploader("Unggah dataset Anda (CSV)", type="csv")

    if uploaded_file:
        # Membaca dataset
        df = pd.read_csv(uploaded_file)
        st.write("Dataset berhasil dimuat. Berikut adalah beberapa baris pertama:")
        st.dataframe(df.head())

        # **Langkah 3: Preprocessing Data**
        st.header("Langkah 3: Preprocessing Data")
        df = df.drop_duplicates().dropna()

        if 'transaction_date' in df.columns:
            df['transaction_date'] = pd.to_datetime(df['transaction_date'], errors='coerce')
            df['month'] = df['transaction_date'].dt.month

        df['total_sales'] = df['unit_price'] * df['total_qty']

        # Normalisasi data
        numeric_features = ['unit_price', 'total_qty', 'total_sales']
        scaler = MinMaxScaler()
        df[numeric_features] = scaler.fit_transform(df[numeric_features])

        st.write("Data setelah preprocessing:")
        st.dataframe(df.head())

        # **Langkah 4: Evaluasi Silhouette Score**
        st.header("Langkah 4: Evaluasi Silhouette Score")
        silhouette_scores = []
        for n_clusters in range(2, 16):
            kmeans = KMeans(n_clusters=n_clusters, random_state=42)
            labels = kmeans.fit_predict(df[numeric_features])
            silhouette_avg = silhouette_score(df[numeric_features], labels)
            silhouette_scores.append({'Jumlah Cluster': n_clusters, 'Silhouette Score': silhouette_avg})
        silhouette_df = pd.DataFrame(silhouette_scores)
        st.write("Silhouette Scores untuk setiap jumlah cluster:")
        st.dataframe(silhouette_df)

        # Visualisasi Silhouette Score
        fig, ax = plt.subplots(figsize=(8, 5))
        sns.lineplot(data=silhouette_df, x='Jumlah Cluster', y='Silhouette Score', marker='o')
        ax.set_title("Evaluasi Silhouette Score")
        ax.set_xlabel("Jumlah Cluster")
        ax.set_ylabel("Silhouette Score")
        st.pyplot(fig)

        # **Langkah 5: Clustering dengan PCA**
        st.header("Langkah 5: Clustering dengan PCA")
        n_clusters = st.slider("Pilih jumlah cluster (2-15):", min_value=2, max_value=15, value=3)
        kmeans = KMeans(n_clusters=n_clusters, random_state=42)

        # Geser label cluster agar dimulai dari 2
        df['cluster'] = kmeans.fit_predict(df[numeric_features]) + 2

        pca = PCA(n_components=2)
        pca_features = pca.fit_transform(df[numeric_features])
        df['pca_1'] = pca_features[:, 0]
        df['pca_2'] = pca_features[:, 1]

        # Visualisasi PCA
        fig, ax = plt.subplots(figsize=(8, 6))
        sns.scatterplot(data=df, x='pca_1', y='pca_2', hue='cluster', palette='viridis', ax=ax)
```

```python
        ax.set_title(f'Visualisasi Cluster dengan {n_clusters} Cluster (PCA)')
        ax.set_xlabel('PCA 1')
        ax.set_ylabel('PCA 2')
        st.pyplot(fig)

        # **Langkah 6: Interpretasi Cluster dengan Chatbot**
        st.header("Langkah 6: Interpretasi AI")
        cluster_summary = df.groupby('cluster')[numeric_features].mean().reset_index()
        st.write(f"Ringkasan rata-rata per cluster untuk {n_clusters} cluster:")
        st.dataframe(cluster_summary)

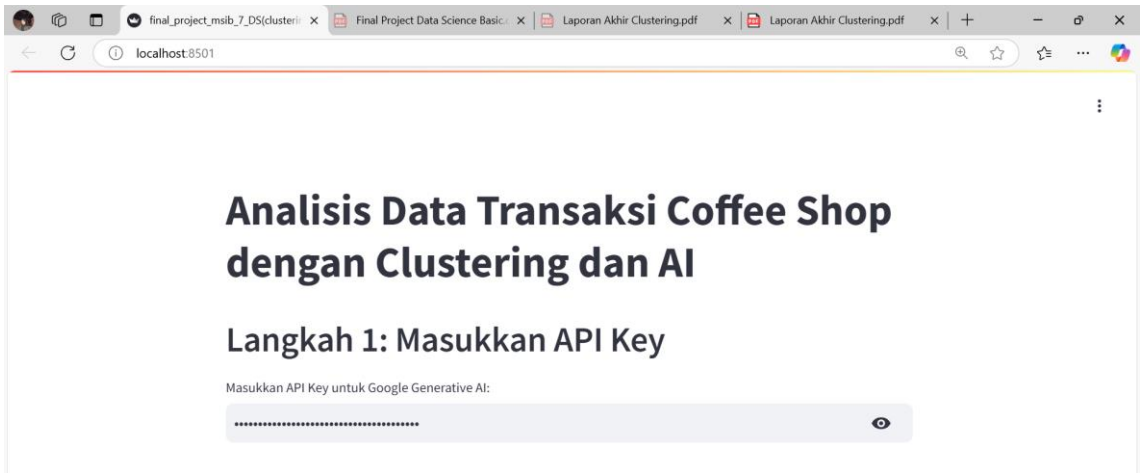
        # Siapkan prompt untuk chatbot
        contexts = tabulate(cluster_summary, headers='keys', tablefmt='grid', showindex=False)
        question = st.text_input("Ajukan pertanyaan tentang hasil clustering (misal: Apa karakteristik tiap cluster?)")

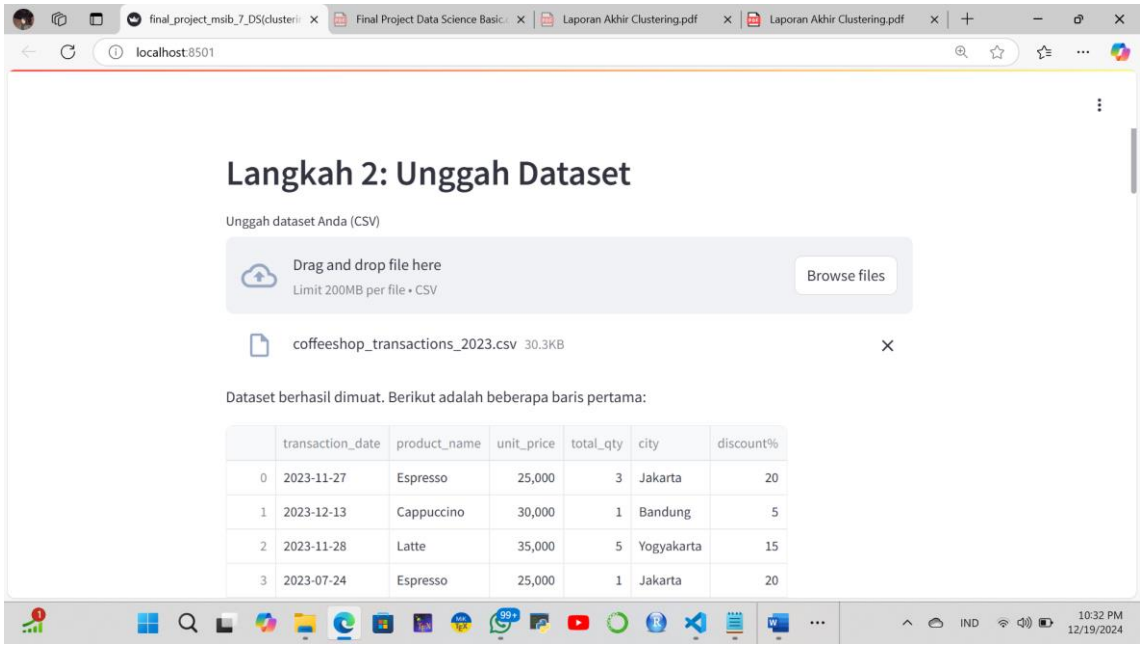
        if question:
            try:
                llm = ChatGoogleGenerativeAI(model="gemini-1.5-flash", api_key=api_key, temperature=0.7)
                prompt = ChatPromptTemplate.from_messages([
                    ("system", "Anda adalah asisten AI yang membantu menjelaskan hasil clustering berdasarkan data yang diberikan."),
                    ("human", f"Berikut adalah data clustering:\n{contexts}\n\nPertanyaan: {question}")
                ])
                messages = prompt.format_messages()
                response = llm.invoke(messages)
                st.write("Jawaban AI:")
                st.write(response.content)
            except Exception as e:
                st.error(f"Terjadi kesalahan saat memproses permintaan AI: {e}")
    else:
        st.info("Silakan unggah dataset Anda untuk memulai analisis.")
```

```
PS C:\Users\Lenovo> cd .\Downloads\
PS C:\Users\Lenovo\Downloads> streamlit run '.\final_project_msib_7_DS(clusteringg).py'

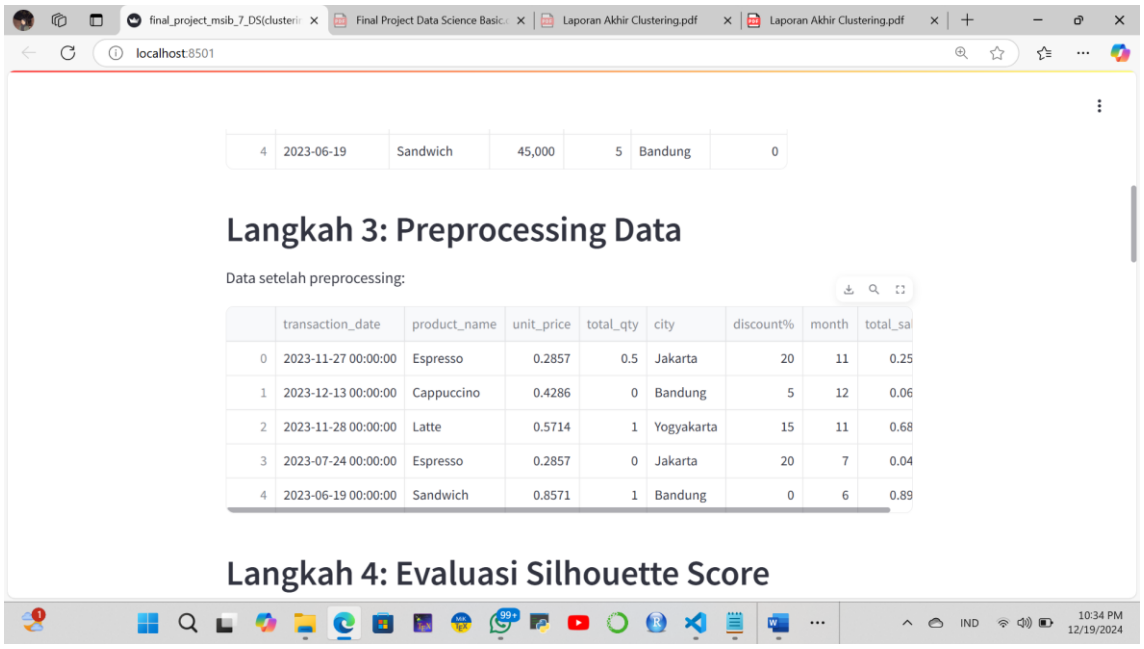
  You can now view your Streamlit app in your browser.

  Local URL: http://localhost:8501
  Network URL: http://192.168.1.5:8501
```





	transaction_date	product_name	unit_price	total_qty	city	discount%
0	2023-11-27	Espresso	25,000	3	Jakarta	20
1	2023-12-13	Cappuccino	30,000	1	Bandung	5
2	2023-11-28	Latte	35,000	5	Yogyakarta	15
3	2023-07-24	Espresso	25,000	1	Jakarta	20



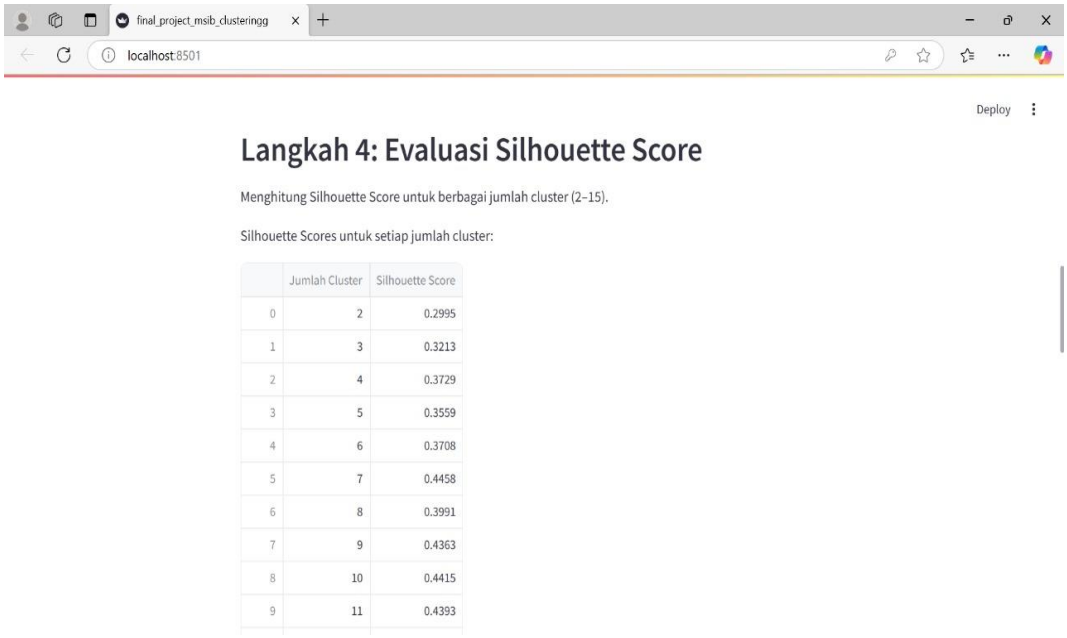
4	2023-06-19	Sandwich	45,000	5	Bandung	0

Langkah 3: Preprocessing Data

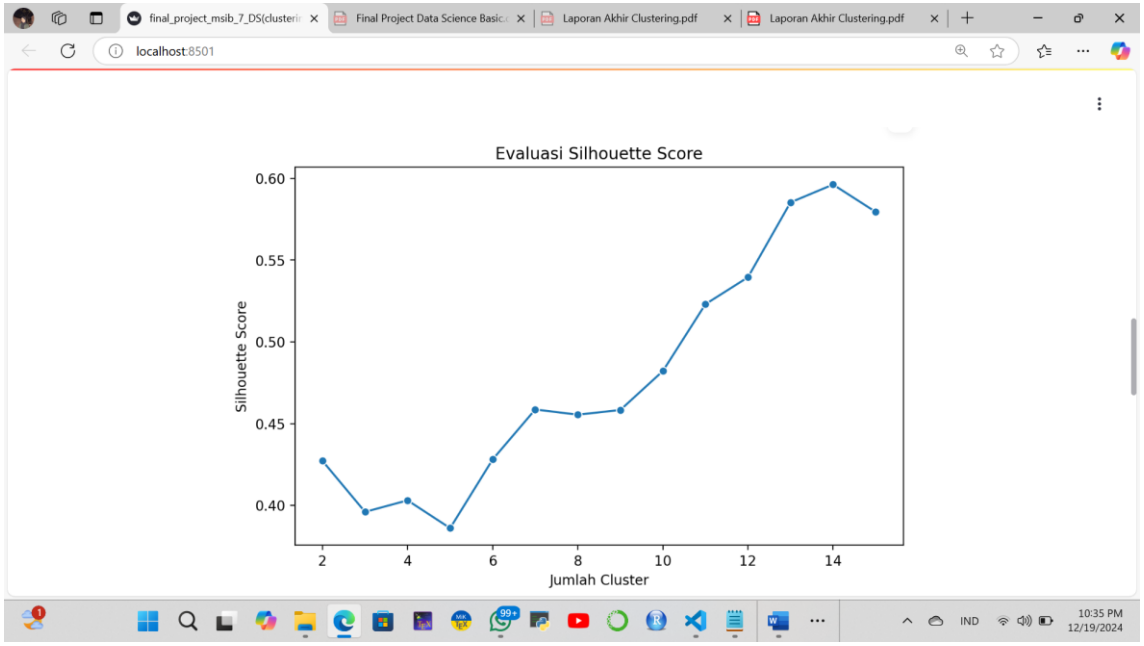
Data setelah preprocessing:

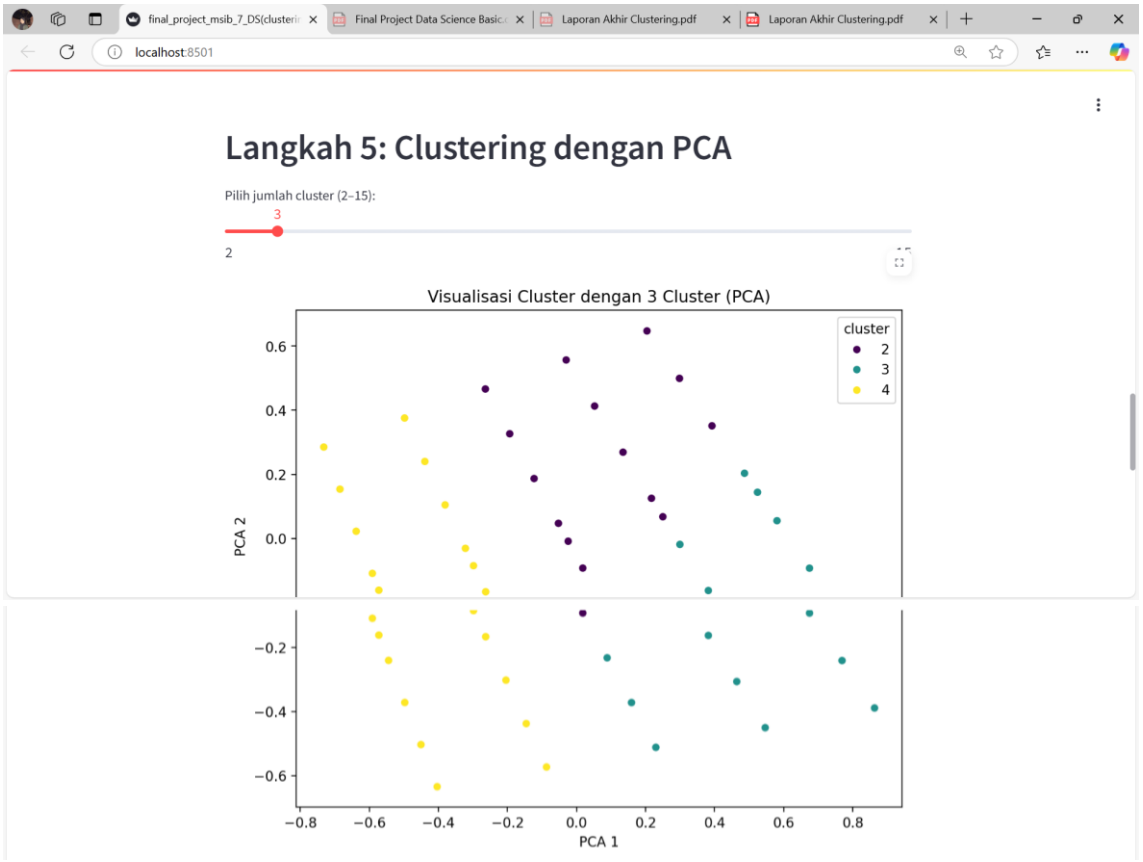
	transaction_date	product_name	unit_price	total_qty	city	discount%	month	total_sa
0	2023-11-27 00:00:00	Espresso	0.2857	0.5	Jakarta	20	11	0.25
1	2023-12-13 00:00:00	Cappuccino	0.4286	0	Bandung	5	12	0.06
2	2023-11-28 00:00:00	Latte	0.5714	1	Yogyakarta	15	11	0.68
3	2023-07-24 00:00:00	Espresso	0.2857	0	Jakarta	20	7	0.04
4	2023-06-19 00:00:00	Sandwich	0.8571	1	Bandung	0	6	0.89

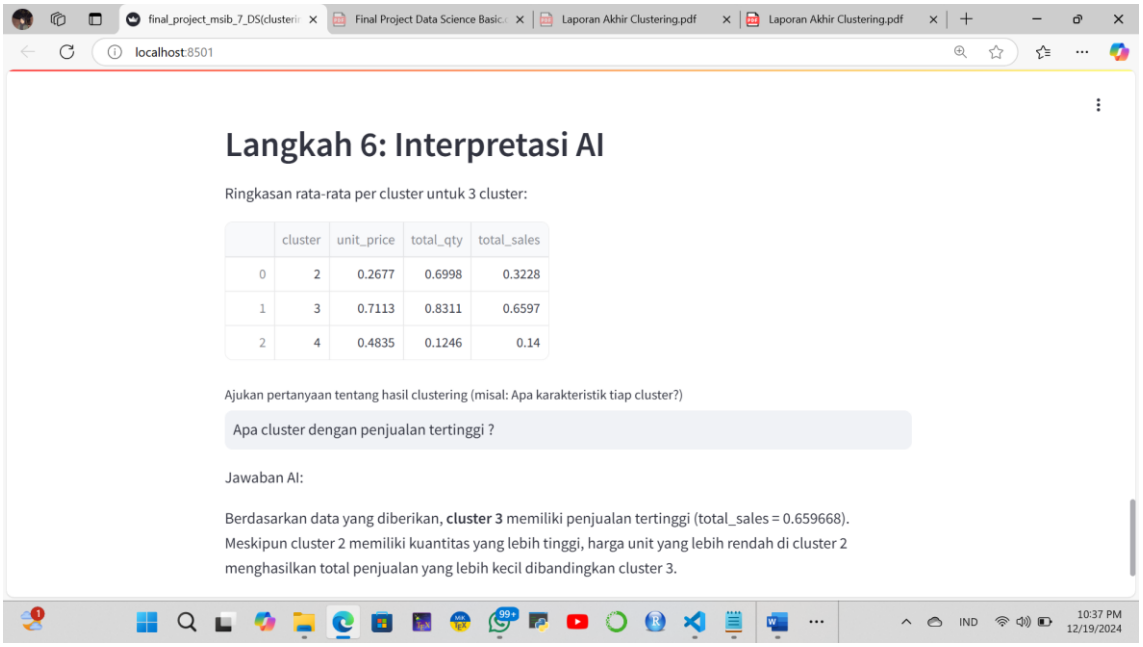
Langkah 4: Evaluasi Silhouette Score



	Jumlah Cluster	Silhouette Score
0	2	0.2995
1	3	0.3213
2	4	0.3729
3	5	0.3559
4	6	0.3708
5	7	0.4458
6	8	0.3991
7	9	0.4363
8	10	0.4415
9	11	0.4393




localhost:8501
Langkah 5: Clustering dengan PCA
Pilih jumlah cluster (2-15):
3
2
Visualisasi Cluster dengan 3 Cluster (PCA)
cluster
2
3
4
PCA 2
PCA 1
0.6
0.4
0.2
0.0
−0.2
−0.4
−0.6
−0.8
−0.6
−0.4
−0.2
0.0
0.2
0.4
0.6
0.8


localhost:8501
Langkah 6: Interpretasi AI
Ringkasan rata-rata per cluster untuk 3 cluster:
cluster unit_price total_qty total_sales
0 2 0.2677 0.6998 0.3228
1 3 0.7113 0.8311 0.6597
2 4 0.4835 0.1246 0.14
Ajukan pertanyaan tentang hasil clustering (misal: Apa karakteristik tiap cluster?)
Apa cluster dengan penjualan tertinggi ?
Jawaban AI:
Berdasarkan data yang diberikan, cluster 3 memiliki penjualan tertinggi (total_sales = 0.659668). Meskipun cluster 2 memiliki kuantitas yang lebih tinggi, harga unit yang lebih rendah di cluster 2 menghasilkan total penjualan yang lebih kecil dibandingkan cluster 3.
IND
10:37 PM
12/19/2024